

IZVJEŠTAJ: Analiza DNA sekvenci žaba pomoću k-mer značajki

1. Sažetak metodologije

U analizi su korištene DNA sekvence tri vrste žaba preuzete iz NCBI baze podataka. Sekvence su spremljene u FASTA formatu i obrađene pomoću Python programa.

Za predstavljanje DNA sekvenci korišten je **k-mer pristup**. Sekvence su podijeljene na fragmente dužine 100 baznih parova. Za svaki fragment izračunate su frekvencije k-mer podsekvenci za vrijednosti:

- $k = 3$
- $k = 4$
- $k = 5$
- $k = 6$

Dobivene k-mer frekvencije korištene su kao ulazne značajke za PCA analizu i klasifikacijske modele.

Za smanjenje dimenzionalnosti korišten je **PCA (Principal Component Analysis)**, pri čemu su analizirane prve dvije glavne komponente.

Za klasifikaciju su korištene metode:

- Logistic Regression
- Support Vector Machine (SVM)
- Random Forest

Podaci su podijeljeni na trening i test skup u omjeru 70:30, uz stratifikaciju prema vrstama.

2. Vježba 1

Analiza tri vrste

U prvoj analizi korištene su tri DNA sekvence:

- frog_species_1
- frog_species_2
- frog_species_3


Dužine sekvenci bile su:

Vrsta	Dužina
frog_species_ 1	17553 bp
frog_species_ 2	2296 bp
frog_species_ 3	310 bp

Zbog vrlo malog broja originalnih sekvenci nije bilo moguće napraviti pouzdanu klasičnu train/test klasifikaciju. Zbog toga je analiza prvenstveno korištena za PCA vizualizaciju i ispitivanje k-mer značajki.


PCA rezultati

k	PC1	PC2
3	61.35%	38.65%
4	69.41%	30.59%
5	69.93%	30.07%
6	60.28%	39.72%



Slika 1: PCA vizualizacija za k=3


Figure 1



(x, y) = (7.66, 7.49)


Slika 2: PCA vizualizacija za k=4

Figure 1



Slika 3: PCA vizualizacija za k=5

Figure 1



Slika 4: PCA vizualizacija za k=6

Ovdje ubaciti odgovarajuće screenshots.

Zaključak vježbe 1

PCA pokazuje kako se DNA sekvence mogu predstaviti pomoću k-mer značajki i vizualizirati u prostoru smanjenom na dvije dimenzije. Međutim, zbog samo jedne originalne sekvence po vrsti, klasifikacijski rezultati ne bi bili statistički pouzdani.

3. Vježba 2

U drugoj vježbi iz analize je uklonjena treća vrsta, tako da su klasificirane dvije vrste:

- frog_species_1
- frog_species_2

Sekvence su podijeljene na fragmente dužine 100 bp.

Dobiveno je:

Vrsta	Broj fragmenata
frog_species_ 1	175
frog_species_ 2	22
Ukupno	197

Logistic Regression rezultati

k Accuracy

3 86.67%

4 **88.33%**

5 **88.33%**


6 **88.33%**

Najbolji rezultat prema accuracy kriteriju ostvaren je za **k=4**, uz accuracy od **88.33%**.

Međutim, classification report pokazuje da model puno bolje prepoznaje **frog_species_1** nego **frog_species_2**. Na primjer, za k=4:


- frog_species_1: recall = 1.00
- frog_species_2: recall = 0.00

To pokazuje da ukupna accuracy može biti varljiva zbog neravnomjernog broja fragmenata između dvije vrste.




Slika 5: PCA za k=3

Figure 1




Slika 6: PCA za k=4




Slika 7: PCA za k=5

Figure 1




Slika 8: PCA za k=6

Figure 1




Slika 9: Confusion matrix za k=3

Figure 1




Slika 10: Confusion matrix za k=4

Figure 1



Slika 11: Confusion matrix za k=5

Figure 1



Slika 12: Confusion matrix za k=6

Ovdje ubaciti screenshots.

Zaključak vježbe 2

Najbolji rezultat Logistic Regression klasifikacije prema accuracy kriteriju dobiven je za **k=4**, **k=5** i **k=6**, sa 88.33%. Ipak, zbog velikog disbalansa između broja fragmenata dvije vrste, rezultat treba interpretirati oprezno.

4. Vježba 3

U trećoj vježbi korištene su dvije klasifikacijske metode:

1. SVM
2. Random Forest

4.1. SVM

Rezultati SVM klasifikacije:

k Accuracy

3 88.33%

4 88.33%

5 88.33%

6 88.33%

SVM je ostvario jednaku accuracy vrijednost za sve testirane vrijednosti k.

Međutim, classification report pokazuje da je model mnogo uspješniji u prepoznavanju `frog_species_1`, dok je prepoznavanje `frog_species_2` bilo vrlo slabo.

4.2. Random Forest

Rezultati Random Forest klasifikacije:

k Accuracy

3 88.33%

4 88.33%

5 86.67%

6 88.33%

Najbolji rezultat prema accuracy kriteriju ostvaren je za **k=3, k=4 i k=6**, sa 88.33%.

Za k=3 Random Forest je pokazao nešto bolje ponašanje prema drugoj vrsti nego ostali modeli:

- `frog_species_1`: precision 0.90, recall 0.98
- `frog_species_2`: precision 0.50, recall 0.14

Ipak, recall za drugu vrstu je i dalje nizak.

Slika 13: SVM klasifikacijski rezultati

Slika 14: Random Forest klasifikacijski rezultati

Ovdje ubaciti screenshots.

5. Konačni zaključak

U radu je provedena analiza DNA sekvenci pomoću k-mer značajki za vrijednosti k od 3 do 6. PCA je omogućio smanjenje dimenzionalnosti i vizualizaciju razlika između DNA sekvenci.

U klasifikacijskom dijelu korištene su Logistic Regression, SVM i Random Forest metode.

Najveća ostvarena accuracy vrijednost iznosila je **88.33%**. Međutim, rezultati classification reporta pokazuju da je klasifikacija značajno bolja za `frog_species_1` nego za `frog_species_2`.

Glavni razlog je **neuravnotežen dataset**, koji sadrži 175 fragmenata prve vrste i samo 22 fragmenta druge vrste. Zbog toga accuracy sama po sebi nije dovoljna za procjenu kvalitete modela.

Rezultati pokazuju da k-mer reprezentacija može biti korisna za analizu i klasifikaciju DNA sekvenci, ali bi za pouzdaniju procjenu bilo potrebno koristiti veći i uravnoteženiji skup podataka, odnosno veći broj nezavisnih sekvenci za svaku vrstu.